


Redes Neuronales Convolucionales (CNN)




Introducción






Introducción

- En una red densa, debemos hacer flatten las imágenes.
- Mucha información se pierde.
- Una red densa aprende patrones globales.




Introducción

- Las imágenes poseen mucha información por sí mismas que se pierde al hacerlas flatten.



Propiedades de las CNN

- Las CNN aprenden patrones locales aprovechando la estructura 2D de las imágenes.



Propiedades de las CNN

- Los patrones aprendidos por las CNN son invariantes a traslaciones.
- Si un patrón se aprende en una zona, se puede reconocer en cualquier parte de la imagen.
- Requieren menos ejemplos de entrenamiento y generalizan mejor.

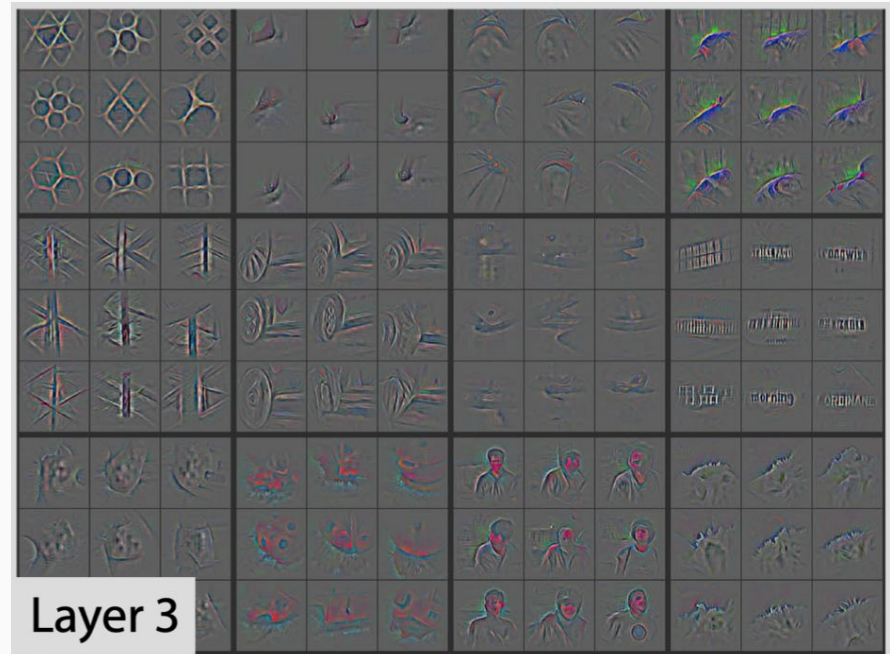



Propiedades de las CNN





Propiedades de las CNN

- Las CNN pueden aprender patrones jerárquicos y clasificadores internos





Propiedades de las CNN

- Las CNN pueden aprender patrones jerárquicos y clasificadores internos




- En ML trataremos a las imágenes como tensores de 3 dimensiones.



Convolución

- El resultado de la convolución es una señal que mezcla propiedades de las señales originales



Convolución

$$a = [\begin{array}{|c|c|c|c|c|c|c|c|} \hline 1 & 5 & 3 & 7 & 5 & 9 & 7 & 10 \\ \hline \end{array}]$$

$$b = [\begin{array}{|c|c|c|} \hline 1 & 0 & 1 \\ \hline \end{array}]$$

$$a*b = [\begin{array}{|c|c|c|c|c|c|} \hline 4 & 12 & 8 & 16 & 12 & 19 \\ \hline \end{array}]$$

Convolución

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

Imagen

1	0	1
0	1	0
1	0	1


Filtro



4		


Feature map

Convolución



$3 \times 3 \times 3$



filter



$62 \times 62 \times 1$


Número de filtros

- Cada filtro genera un feature map.
- Cada feature map codifica características particulares.



$3 \times 3 \times 3$

filter



$62 \times 62 \times 1$

Filtros o Kernels


- Sirven para eliminar información o resaltar propiedades como contornos, esquinas, curvas.



- En vez de seleccionar manualmente filtros, las CNN aprenden filtros que sirven para extraer características relevantes para el problema


Bordes y Padding

- Un efecto de la convolución es la disminución en altura y anchura del mapa de características




Bordes y Padding

- El padding consiste en agregar columnas y filas en las orillas del feature map.
- Muchas veces lo que se busca con el padding es que no decrezcan las dimensiones del feature map después de la convolución.




Stride

- El stride indica la distancia que habrá en la aplicación de un filtro al recorrerlo por el mapa de características.




max-pooling

- Se extraen ventanas del feature map y se obtiene a la salida el valor máximo de cada canal.
- Por lo general se usa en ventanas de 2x2 y con stride de 2, obteniendo a la salida feature maps de la mitad de tamaño.
- Con max-pooling se reduce el número de parámetros y se integran valores vecinos que conducen a representaciones jerárquicas.



Arquitectura completa



Práctica

Clasificación MNIST y Fashion
MNIST con CNN

